Постановка задачи

Цель работы - исследовать различные подходы к прогнозированию временных рядов и определить, какой способ моделирования сезонности является наиболее эффективным.

В рамках работы проверяется гипотеза о том, что добавление различных типов признаков (сезонных лагов, календарных и Фурье-признаков) может улучшить качество прогноза по сравнению с использованием только лаговых признаков.

Данные

В работе используется датасет M4. Для проведения экспериментов было выбрано 100 случайных временных рядов.
Ряды в выборке отличаются по длине, масштабу значений и характеру поведения. Встречаются как ряды с выраженной сезонностью и трендом, так и более шумные или почти стационарные ряды без явной структуры.

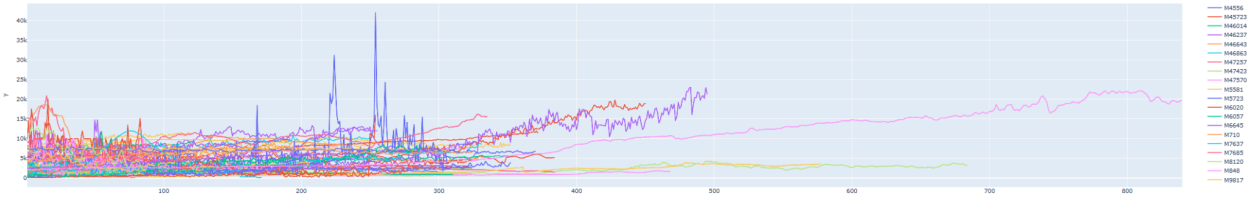

Рисунок 1: График 100 рядов из M4

По графику ACF для 10 рядов видно, что некоторые ряды обладают месячной сезонностью со значимыми 12-ми и 24-ми лагами.

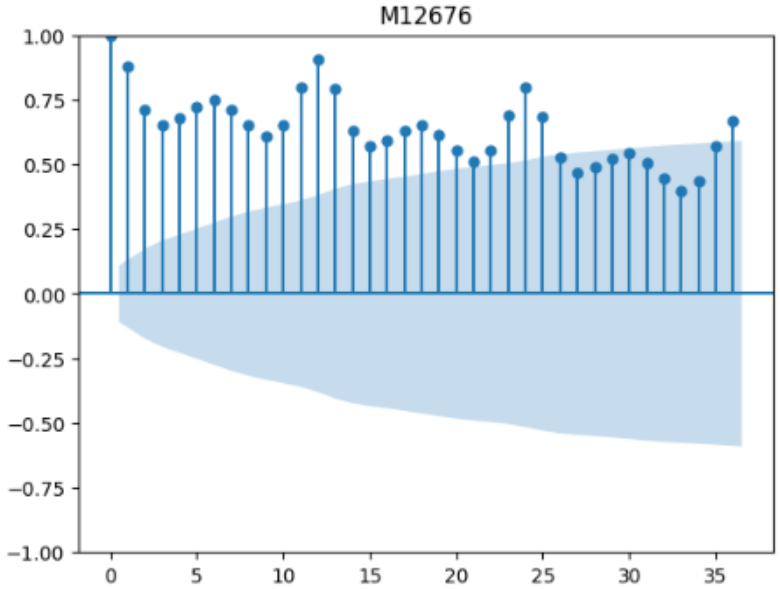

Рисунок 2: График ACF для ряда M12676

Горизонт прогнозирования

Горизонт прогнозирования выбран равным 18. Это значение позволяет оценивать качество моделей на достаточно длинном промежутке времени и захватить период сезонности.

Метрики качества

В качестве метрик использовались:

- **sMAPE** - симметричная относительная ошибка, не чувствительная к масштабу ряда

- **MASE** - относительная ошибка по сравнению с наивным сезонным прогнозом (период сезонности = 12)

Метрика MASE рассчитывается как отношение ошибки модели на тестовой выборке к ошибке наивного сезонного прогноза, вычисленного на обучающей выборке.

Базовые модели

В качестве бейзлайнов были использованы классические модели: **Naive**, **Seasonal Naive**, **AutoETS**, **AutoTheta**.
Данные модели хорошо подходят для временных рядов, так как явно учитывают тренд и сезонность.
Результаты показали, что модели **AutoETS** и **AutoTheta** достигают наилучших значений MASE (< 1) и sMAPE.
При этом их MASE не сильно меньше единицы: 0.97 и 0.99 соответственно.

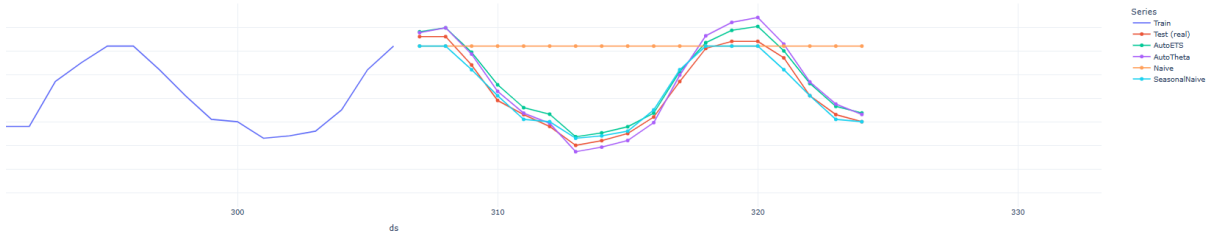

ML-подход

В качестве глобальной модели использовался **CatBoost** с **Direct MIMO** подходом. Были рассмотрены различные варианты признаков: только лаговые признаки, лаги + сезонные лаги, лаги + календарные признаки, лаги + Фурье-признаки, различные комбинации.

Эксперименты

Сравнение наборов признаков

В эксперименте с фиксированными параметрами model_horizon = 6, history = 24 и horizon = 18 наилучшее качество показала модель с лаговыми, сезонными и календарными признаками (sMAPE ≈ 17.40, MASE ≈ 1.47). Использование только лагов дало худший результат, что подтверждает недостаточность учета лишь локальной динамики. Добавление сезонных лагов улучшает качество, а календарные признаки дают небольшой дополнительный эффект. При этом Фурье-признаки не привели к улучшению и оказались избыточными.

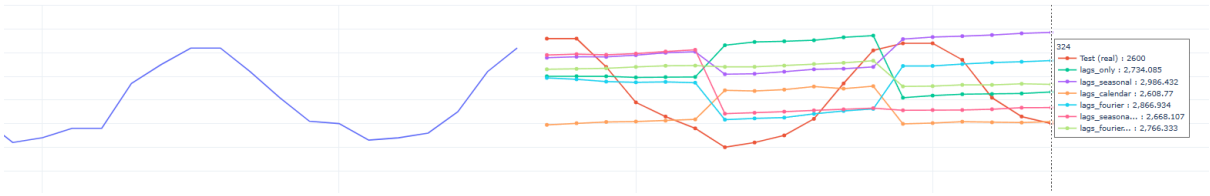

Подбор параметров для лаговых признаков

В эксперименте с использованием только лаговых признаков было установлено, что качество модели существенно зависит от параметров history и model_horizon. Наилучшие результаты достигаются при небольшом горизонте модели (model_horizon = 1) и умеренной или увеличенной длине истории (history = 6–36), где достигаются минимальные значения метрик (sMAPE ≈ 17.23, MASE ≈ 1.41). Увеличение model_horizon приводит к ухудшению качества, так как задача прогнозирования становится сложнее.

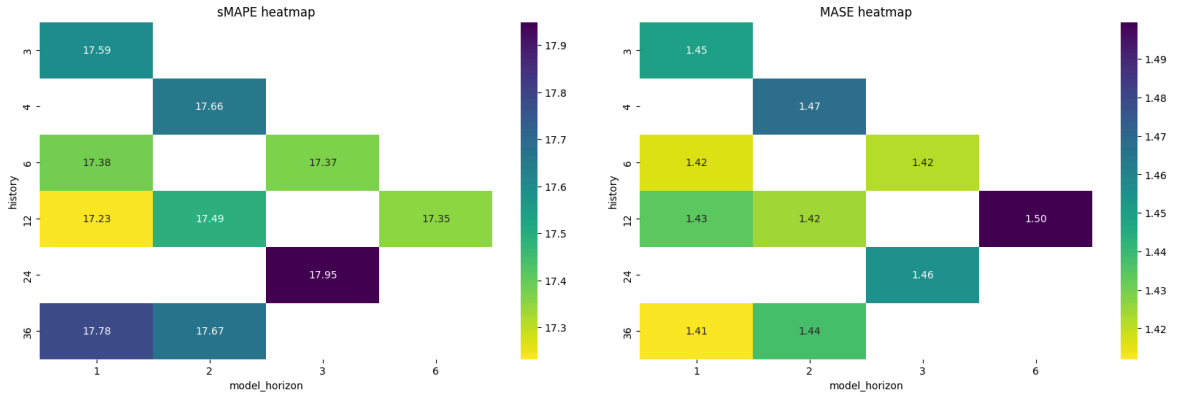

Лаги и сезонные лаги

При добавлении сезонных лагов наблюдается заметное улучшение качества модели по сравнению с использованием только лагов. Наилучшие результаты достигаются при параметрах history = 36 и model_horizon = 1, где достигаются минимальные значения метрик (sMAPE ≈ 16.95, MASE ≈ 1.36). Это

подтверждает, что учет сезонной структуры данных существенно повышает качество прогноза. При увеличении model_horizon качество ухудшается, как и в предыдущем случае. В то же время самой оптимальной длиной истории является серединное значение - 36 месяцев.

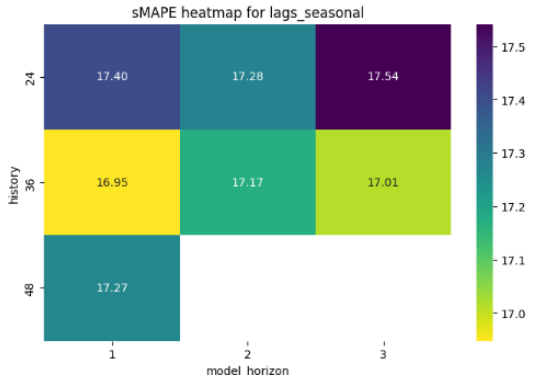

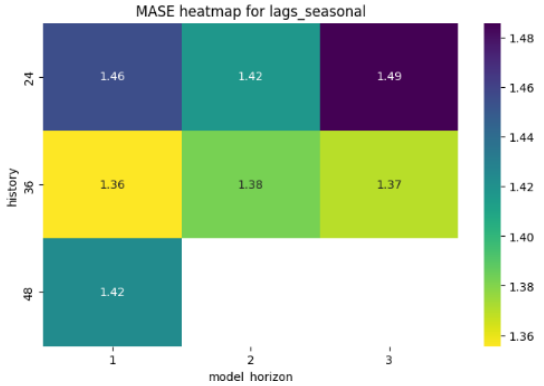

Сезонные лаги и календарные признаки

Добавление календарных признаков к сезонным лагам не привело к существенному улучшению качества модели. В лучшей конфигурации (history = 48, model_horizon = 1) достигаются значения sMAPE ≈ 17.11 и MASE ≈ 1.37, что сопоставимо, но в целом хуже, чем при использовании только сезонных лагов. В данном случае увеличение history и уменьшение model_horizon ведет к улучшению метрик.

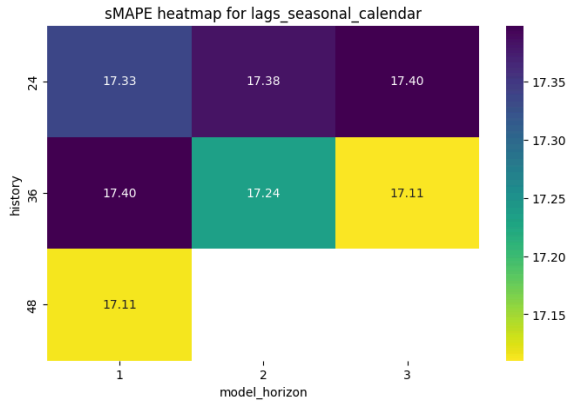

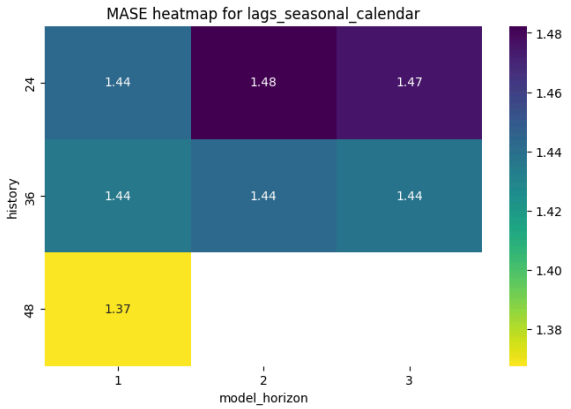

Вывод по экспериментам

Наиболее эффективным способом учета сезонности в данной задаче являются сезонные лаги. Они обеспечивают наилучшие значения метрик и более устойчивое качество по сравнению с другими рассмотренными подходами.

При этом добавление более сложных признаков, таких как календарные и Фурье-признаки, не приводит к улучшению результатов. Кроме того, важную

роль играет выбор параметров модели: небольшие значения model_horizon и умеренная длина истории позволяют достичь лучшего качества прогноза. Таким образом, гипотеза частично подтверждается: учет сезонности действительно важен, однако наиболее эффективным способом ее моделирования является использование сезонных лагов, а не более сложных признаков.

Общий вывод по работе

В ходе работы были исследованы различные подходы к прогнозированию временных рядов, включая базовые модели (Naive, Seasonal Naive, AutoETS, AutoTheta) и ML-подход с использованием лаговых, сезонных, календарных и Фурье-признаков. В качестве метрик качества были выбраны sMAPE и MASE, позволяющие оценить как относительную ошибку прогноза, так и его качество по сравнению с наивной моделью.

Базовые модели показали сильные результаты, особенно AutoTheta и AutoETS, которые обеспечили наилучшие значения метрики MASE < 1. Это указывает на то, что классические методы хорошо захватывают тренд и сезонность во временных рядах.

В рамках ML-подхода было установлено, что наилучшие результаты достигаются при использовании сезонных лагов. Лучшая конфигурация (history = 36, model_horizon = 1) показала значения sMAPE ≈ 16.95 и MASE ≈ 1.36. Использование только лаговых признаков давало более слабые результаты, а добавление календарных и Фурье-признаков не приводило к устойчивому улучшению качества и в ряде случаев даже ухудшало метрики. Это говорит о том, что ключевую роль в данной задаче играет именно учет сезонности.

Несмотря на улучшения внутри ML-подхода, ни одна из моделей не смогла превзойти базовые методы по метрике MASE. Это связано с тем, что AutoETS и AutoTheta явно моделируют структуру ряда (тренд и сезонность), тогда как в ML-подходе эти зависимости восстанавливаются косвенно через признаки.

Таким образом, выдвинутая гипотеза о том, что добавление различных типов признаков (сезонных лагов, календарных и Фурье-признаков) может улучшить качество прогноза по сравнению с использованием только лаговых признаков подтвердилась лишь частично.